

# Прогнозирование намерений. Исследование свойств локальных моделей при пространственном декодировании сигналов головного мозга

*Филатов А.В., Маркин В.О.*

filatov.av@phystech.edu; markin.vo@phystech.edu  
МФТИ

В данной работе рассматривается проблема создания нейрокомпьютерного интерфейса. Особенностью этой проблемы является требование стабильности у моделей. Поэтому при построении таких систем используются простые модели. Важным аспектом создания таких моделей является построение надежного признакового пространства. В данной статье рассматривается построение признакового пространства на данных электрокортикограммы для метода частичной регрессии наименьших квадратов

Основной вклад данной работы заключается в учете пространственной зависимости в модели. В нашем подходе используется пространственная аппроксимация искомого сигнала с помощью нормального распределения и полиномов. Информация об аппроксимации учитывается при создании признакового пространства. В статье приведены результаты численных экспериментов на данных электрокортикограмм головного мозга обезьян.

**Ключевые слова:** *отбор признаков; нейрокомпьютерный интерфейс; электрокортикограмма; локальные модели*

## 1 Введение

Нейрокомпьютерный интерфейс (BCI) [1] позволяет считывать сигналы нейронов головного мозга, анализировать их и переводить в команды исполняющей системы. Исследования в данной области позволяют людям с нарушениями двигательных функций организма заменить или восстановить их. Примером такой системы является система управления роботизированным протезом посредством мозговых импульсов.

Мозговая активность представляет собой совокупность электрических импульсов различной амплитуды и частоты, возникающих в коре головного мозга. Исследование мозговой активности может производиться при помощи электрокортикографии [2] или [3] электроэнцефалографии. На выходе этих процедур мы получаем временной ряд напряжений сигнала, который используется как сырые данные для задачи. В нашей задаче используется данные из [4].

Стандартные подходы к решению задачи состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала [5, 6]. Большинство методов в смежных работах исследуют частотные характеристики [7–9]. Наиболее распространёнными моделями являются алгоритмы PLS [8, 10, 11], PCA [10, 11]. В работе [12] используются алгоритмы, построенные на скрытых марковских моделях. В работах [9, 13] авторы рассматривают различные участки сигнала в виде слов. В работе [14] задача отбора признаков сводится к задаче квадратичного программирования (Quadratic Programming Feature Selection [15]). Также для решения задачи используются нейросетевые модели [16].

## 2 Постановка задачи

Данные электрокортикограммы представляют собой временной ряд амплитуд сигналов  $\mathbf{X}(t_i) \in \mathbb{R}^m$ , по которым нужно предсказать положение запястья в следующем момент времени  $\mathbf{y}(t_{i+1}) \in \mathbb{R}^3$ . В качестве выборки рассматривается  $\mathfrak{D} = \{(X_i^{i+n_{wind}}, \mathbf{y}_{i+1})\}$ , где  $X_i^{i+n_{wind}}$  — значения временного ряда с момента времени  $i$  по момент  $i + n_{wind}$ , где  $n_{wind}$  — гиперпараметр задачи и выбирается из дополнительных условий. В силу коррелированности исходных данных предлагается разбить предсказательную модель на локальную модель и модель регрессии.

**Определение 1.** *Локальная модель — совокупность двух отображений:  $\varphi$  и  $\psi$ , где  $\varphi$  отображает из пространства большей размерности в пространство меньшей размерности, а  $\psi$  отображает из этого же пространства меньшей размерности в исходное пространство большей размерности, при чем при применение композиции  $\psi \circ \varphi$  сохраняется максимальное количество информации*

В нашем случае под количеством информации понимается дисперсия. Оптимизационная задача на нахождение локальной модели ставится следующим образом

$$\begin{aligned}\varphi : \mathbb{R}^{N_{wind} \times m} &\rightarrow \mathbb{R}^{N_{wind} \times n} \\ \psi : \mathbb{R}^{N_{wind} \times n} &\rightarrow \mathbb{R}^{N_{wind} \times m} \\ \psi^*, \varphi^* &= \arg \min_{\psi, \varphi} \|\mathbf{S} - \psi \circ \varphi(\mathbf{S})\|_2\end{aligned}$$

После нахождения локальной модели получаем новую выборку  $\mathfrak{D}_{new} = \{(z_i^{i+n_{wind}}, \mathbf{x}_i)\}$ ,  $z_i^{i+n_{wind}} = \varphi(S_i^{i+n_{wind}})$ . Эту задачу мы решаем при помощи регрессии:

$$W^* = \arg \min_W L(\mathbf{z}, \mathbf{W}, \mathbf{y})$$

Критерием качества линейной модели выступает коэффициент детерминации или  $R^2$ , как основной критерий в задачах линейной регрессии.

Разбиение выборки производится в следующем соотношении: 80% — обучение, 20% — тестирование.

## Литература

- [1] Jerry J Shih, Dean J Krusienski, and Jonathan R Wolpaw. Brain-computer interfaces in medicine. In *Mayo Clinic Proceedings*, volume 87, pages 268–279. Elsevier, 2012.
- [2] N Jeremy Hill, Disha Gupta, Peter Brunner, Aysegul Gunduz, Matthew A Adamo, Anthony Ritaccio, and Gerwin Schalk. Recording human electrocorticographic (ecog) signals for neuroscientific research and real-time functional cortical mapping. *JoVE (Journal of Visualized Experiments)*, (64):e3993, 2012.
- [3] Michael J Aminoff. Electroencephalography: general principles and clinical applications. *Electrodiagnosis in Clinical Neurology*, 6th ed.; Aminoff, MJ, Ed, pages 37–84, 2012.
- [4] Zenas C Chao, Yasuo Nagasaka, and Naotaka Fujii. Long-term asynchronous decoding of arm motion using electrocorticographic signals in monkey. *Frontiers in neuroengineering*, 3:3, 2010.
- [5] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiro Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ecogs during periodic movements. *Frontiers in neuroscience*, 8:417, 2014.
- [6] David M Alexander, Peter Jurica, Chris Trengove, Andrey R Nikolaev, Sergei Gepshtein, Mikhail Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, et al. Traveling waves and trial averaging: the nature of single-trial and averaged brain responses in large-scale cortical signals. *Neuroimage*, 73:95–112, 2013.
- [7] César Márquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral components and kinematic recordings. *Journal of neural engineering*, 4(2):146, 2007.
- [8] Andrey Elishev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand trajectories from ecog signals using the generalized additive model. *Journal of neural engineering*, 11(6):066005, 2014.
- [9] Carlos A Loza and Jose C Principe. Unsupervised robust detection of behavioral correlates in ecog. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*, pages 509–512. IEEE, 2017.
- [10] Andrey Elishev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ecog) recording. *PloS one*, 11(5), 2016.
- [11] Roman Rosipal and Nicole Kramer. Overview and recent advances in partial least squares. In *International Statistical and Optimization Perspectives Workshop Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer, 2005.
- [12] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*, pages 1858–1862. IEEE, 2014.
- [13] Hai-bin Zhao, Chun-yang Yu, Chong Liu, and Hong Wang. Ecog-based brain-computer interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International Conference on Biomedical Engineering and Informatics*, volume 2, pages 873–877. IEEE, 2010.
- [14] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ecog-based brain-computer interface. *Expert Systems with Applications*, 114:402–413, 2018.
- [15] Irene Rodriguez-Lujan, Ramon Huerta, Charles Elkan, and Carlos Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 11(Apr):1491–1516, 2010.
- [16] Ziqian Xie. Deep learning approach for brain machine interface. 2018.

Поступила в редакцию