

Исследование свойств локальных аппроксимирующих моделей в задаче декодирования сигналов головного мозга

Филатов А.В., Маркин В.О., Стрижов В.В
filatov.av@phystech.edu; markin.vo@phystech.edu
МФТИ

В данной работе рассматривается проблема создания нейрокомпьютерного интерфейса. Особенностью этой проблемы является требование к устойчивости моделей. Под устойчивостью модели понимается малое изменение выходных данных при малом изменении входных данных. Одним из подходов в задаче декодирования сигнала, удовлетворяющему требованию устойчивости, являются локальные модели. В данной статье рассматривается построение локальной модели на данных электрокортикограммы.

Основной вклад данной работы заключается в построении локальной модели за счет пространственной информации. В предложенном подходе пространственная аппроксимация искомого сигнала строится при помощи нормального распределения и полиномов. Параметризация, полученная при помощи локальной модели, рассматривается как новое признаковое пространство для задачи Food-Tracking. В статье приведены результаты численных экспериментов на данных электрокортикограмм головного мозга обезьян.

Ключевые слова: *отбор признаков; нейрокомпьютерный интерфейс; электрокортикограмма; локальные модели*

1 Введение

Нейрокомпьютерный интерфейс (Brain-Computer Interface, BCI) [1] считывает сигналы поверхности кортекса головного мозга, анализирует и переводит в команды исполняющей системы. Исследования в данной области позволяют людям заменить или восстановить нарушенные двигательные функции организма. Примером такой системы является система управления роботизированным протезом посредством мозговых импульсов.

Мозговая активность [2] представляет собой совокупность электрических импульсов различной амплитуды и частоты, возникающих на поверхности кортекса головного мозга. Исследование мозговой активности производится при помощи электрокортикографии [3] или электроэнцефалографии [4]. Результатом измерений является временной ряд напряжений сигнала, который используется в задаче декодирования сигнала. Для исследования используется данные из [5].

Подходы [6, 7] к решению задачи состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала. В [8–10] исследуются частотные характеристики кортикограмм. Основными методами решения являются линейные модели, такие как метод частичных регрессии наименьших квадратов (Partial Least Squares, PLS) [9, 11, 12] и метод главных компонент (Principal Component Analysis, PCA) [11, 12]. Важным аспектом создания таких моделей является построение надежного признакового пространства. В [13] используются алгоритмы, построенные на скрытых марковских моделях. В [10, 14] рассматриваются различные участки сигнала в виде слов. В работе [2] задача отбора признаков сводится к задаче квадратичного программирования (Quadratic Programming Feature Selection) [15]. Также для решения задачи используются нейросетевые модели [16].




Рис. 1 Пример движения запястья

2 Постановка задачи

Данные электрокортикограммы представляют собой временной ряд амплитуд сигналов $\mathbf{X}(t) \in \mathbb{R}^m$, по которым требуется предсказать положение запястья в следующем момент времени $\mathbf{y}(t+1) \in \mathbb{R}^3$. В качестве выборки рассматривается $\mathfrak{D} = \{(\mathbf{X}_t^n, \mathbf{y}_{t+1})\}$, где \mathbf{X}_t^n — значения временного ряда с момента времени t по момент $t+n$, где n — горизонт прогнозирования задачи. В силу коррелированности исходных данных предлагается построить предсказательную модель как композицию локальной модели и линейной модели.

Определение 1. Локальная модель — совокупность двух параметрических отображений: φ и ψ

$$\begin{aligned}\varphi &: \mathbb{R}^{n \times k_1} \rightarrow \mathbb{R}^{n \times k_2} \\ \psi &: \mathbb{R}^{n \times k_2} \rightarrow \mathbb{R}^{n \times k_1} \\ \psi^*, \varphi^* &= \arg \min_{\psi, \varphi} \|\mathbf{X} - \psi \circ \varphi(\mathbf{X})\|_2,\end{aligned}$$

где φ отображает из пространства большей размерности в пространство меньшей размерности, а ψ отображает из этого же пространства меньшей размерности в исходное пространство большей размерности.

Определение 2. Под сложностью модели понимается число оптимизируемых параметров.

В нашем случае число оптимизируемых параметров прямо пропорционально только числу параметров локальной модели, поэтому далее везде под сложностью будет пониматься число параметров локальной модели.

Определение 3. Пусть f — модель, x, y — произвольные элементы из генеральной совокупности, такие что расстояние $\rho(x, y) < \varepsilon$. Тогда модель f называется устойчивой если

$$\|f(x) - f(y)\| \leq C \cdot \varepsilon, \text{ где } C = \text{const}.$$

Локальная модель порождает новую выборку $\mathfrak{D}_{\text{new}} = \{(\mathbf{Z}_{(i)}^n, \mathbf{y}_i)\}$, $\mathbf{Z}_{(i)}^n = \varphi(\mathbf{X}_{(i)}^n)$. На этой выборке строится линейная модель, которая решает конечную задачу:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{z}, \mathbf{w}, \mathbf{y})$$

Критерием качества линейной модели выступают коэффициент детерминации и корреляция Пирсона.

3 Описание алгоритма

3.1 Алгоритм

Решение задачи строится как композиция:

$$g^* = f \circ \varphi,$$

где φ — локальная модель, а f — решение задачи регрессии методом частичных квадратов

3.2 Локальная модель

Пусть заданы координаты каждого электрода на плоскости $\mathbf{Z} = \{\mathbf{z}_j \in \mathbb{R}^2, j \in 1, \dots, N_{\text{ch}}\}$. Зафиксируем произвольный момент времени t . Тогда представим вектор значений $\mathbf{x}(t)$ амплитуд на электродах в момент t , как вектор-функцию $\mathbf{g}(\mathbf{Z})$ от координат электродов. Вектор-функцию $\mathbf{g}(\mathbf{Z})$ ищем в классе полиномов $\{z_{0j}^i z_{1j}^k\}_{i,k=0}^n$, где z_{0j} и z_{1j} соответственно первая и вторая координаты j -го электрода, а n — максимальная степень полинома. Находим $\mathbf{g}^*(\mathbf{Z})$ как решение задачи оптимизации:

$$\mathbf{g}^* = \arg \min_{\mathbf{g}} \|\mathbf{x}(t) - \mathbf{g}(\mathbf{Z}, \Theta)\|_2^2$$

Отображение φ строим как:

$$\varphi : \mathbf{x}(t) \rightarrow \Theta(t),$$

где Θ веса $\mathbf{g}^*(t)$.

3.3 Метод частичных квадратов (PLS)

Метод частичных наименьших квадратов проецирует матрицу плана \mathbf{X} и целевую матрицу \mathbf{Y} в скрытое пространство малой размерностью l ($l < M$). Метод PLS находит в скрытом пространстве матрицы $\mathbf{T}, \mathbf{U} \in \mathbb{R}^{m \times l}$, которые лучше всего описывают оригинальные матрицы \mathbf{X} и \mathbf{Y} . При этом PLS максимизирует взаимосвязь между \mathbf{T} и \mathbf{U} . Матрица плана \mathbf{X} и целевая матрица \mathbf{Y} проецируются в скрытое пространство следующим образом:

$$\begin{aligned} \mathbf{X}_{m \times n} &= \mathbf{T}_{m \times l} \cdot \mathbf{P}_{l \times n}^T + \mathbf{B}_{m \times n} = \sum_{k=1}^l \mathbf{t}_k \cdot \mathbf{p}_k^T + \mathbf{B}_{m \times n}, \\ \mathbf{Y}_{m \times r} &= \mathbf{U}_{m \times l} \cdot \mathbf{Q}_{l \times r}^T + \mathbf{C}_{m \times r} = \sum_{k=1}^l \mathbf{u}_k \cdot \mathbf{q}_k^T + \mathbf{C}_{m \times r}. \end{aligned}$$

Здесь \mathbf{T} и \mathbf{U} — образы исходных матриц в скрытом пространстве, причём столбцы матрицы \mathbf{T} ортогональны; \mathbf{P} и \mathbf{Q} — матрицы перехода; \mathbf{B} и \mathbf{C} — матрицы остатков. Метод PLS максимизирует линейную зависимость между столбцами матриц \mathbf{T} и \mathbf{U}

$$\mathbf{U} \approx \mathbf{T}\mathbf{B}, \mathbf{B} = \text{diag}(\beta_k), \quad \beta_k = \mathbf{u}_k^T \mathbf{t}_k / (\mathbf{t}_k^T \mathbf{t}_k).$$

Предсказание строится как $\hat{\mathbf{Y}} = \mathbf{X}\mathbf{R}$, где $\mathbf{R} = \mathbf{W}(\mathbf{P}^T \mathbf{W})^{-1}(\mathbf{T}^T \mathbf{T})^{-1} \mathbf{T}^T$, а \mathbf{W} — обучающая матрица весов для поддержания ортогональности.

4 Вычислительный эксперимент

4.1 Данные

В качестве данных для проведения вычислительного эксперимента использовались данные [5], представляющие запись электрокортикограммы головного мозга обезьяны. Каждой записи соответствует амплитуды напряжения на 32 электродах и 3 пространственные координаты. При проведении эксперимента выборка была сокращена в 10 раз.




Рис. 2 Спектрограмма за первые 10 секунд

Обработка исходных данных производится в несколько этапов и подробно описано в статье [14]. Исходный сигнал записан на частоте 1 кГц, данные о движении — на частоте 120 Гц. Сигнал фильтруется полосным фильтром с диапазоном от 0.3 до 600 Гц. Затем для каждого момента времени t строится частотно-временная характеристика. Над сигналом в окне $[t - 1.1s, t]$ с шагом в $\Delta = 100$ миллисекунд осуществляется вейвлет-преобразование на 10 различных частотах ω_j в диапазоне от 10 до 150 Гц. Затем строится матрица 10×12 , элементами которой s_{ij} является квадрат амплитуды на частоте ω_j в момент времени $t - (1 + i)\Delta$. Таким образом, размер описания одного объекта (момента времени) составляет $N_{ch} \times 10 \times 12$.

При проведении эксперимента разбиение выборки производится в следующем соотношении: 80% — обучение, 20% — тестирование.

4.2 Результаты локальной модели

4.3 Результаты линейной регрессии

Метод	R^2 score	Пирсона	Сложность	Устойчивость	Ошибка аппроксимации
Без			32		
Poly 2			10		
Normal			5		

Таблица 1 Сравнение результатов




Рис. 3 Зависимость MSE аппроксимирующей модели от времени




Рис. 4 Зависимость скорости от времени

Литература

- [1] Jerry J Shih, Dean J Krusienski, and Jonathan R Wolpaw. Brain-computer interfaces in medicine. In *Mayo Clinic Proceedings*, volume 87, pages 268–279. Elsevier, 2012.
- [2] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ecog-based brain-computer interface. *Expert Systems with Applications*, 114:402–413, 2018.
- [3] N Jeremy Hill, Disha Gupta, Peter Brunner, Aysegul Gunduz, Matthew A Adamo, Anthony Ritaccio, and Gerwin Schalk. Recording human electrocorticographic (ecog) signals for neuroscientific research and real-time functional cortical mapping. *JoVE (Journal of Visualized Experiments)*, (64):e3993, 2012.
- [4] Michael J Aminoff. Electroencephalography: general principles and clinical applications. *Electrodiagnosis in Clinical Neurology*, 6th ed.; Aminoff, MJ, Ed, pages 37–84, 2012.
- [5] Zenas C Chao, Yasuo Nagasaka, and Naotaka Fujii. Long-term asynchronous decoding of arm motion using electrocorticographic signals in monkey. *Frontiers in neuroengineering*, 3:3, 2010.
- [6] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiro Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ecogs during periodic movements. *Frontiers in neuroscience*, 8:417, 2014.
- [7] David M Alexander, Peter Jurica, Chris Trengove, Andrey R Nikolaev, Sergei Gepshtein, Mikhail Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, et al. Traveling waves and trial averaging: the nature of single-trial and averaged brain responses in large-scale cortical signals. *Neuroimage*, 73:95–112, 2013.
- [8] César Márquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral components and kinematic recordings. *Journal of neural engineering*, 4(2):146, 2007.
- [9] Andrey Eliseyev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand trajectories from ecog signals using the generalized additive model. *Journal of neural engineering*, 11(6):066005, 2014.
- [10] Carlos A Loza and Jose C Principe. Unsupervised robust detection of behavioral correlates in ecog. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*, pages 509–512. IEEE, 2017.
- [11] Andrey Eliseyev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ecog) recording. *PloS one*, 11(5), 2016.
- [12] Roman Rosipal and Nicole Kramer. Overview and recent advances in partial least squares. In *International Statistical and Optimization Perspectives Workshop Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer, 2005.
- [13] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*, pages 1858–1862. IEEE, 2014.
- [14] Hai-bin Zhao, Chun-yang Yu, Chong Liu, and Hong Wang. Ecog-based brain-computer interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International Conference on Biomedical Engineering and Informatics*, volume 2, pages 873–877. IEEE, 2010.
- [15] Irene Rodriguez-Lujan, Ramon Huerta, Charles Elkan, and Carlos Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 11(Apr):1491–1516, 2010.
- [16] Ziqian Xie. Deep learning approach for brain machine interface. 2018.

Поступила в редакцию