

Исследование свойств локальных моделей в задаче декодирования сигналов головного мозга

Филатов А.В., Маркин В.О.

filatov.av@phystech.edu; markin.vo@phystech.edu

МФТИ

В данной работе рассматривается проблема создания нейрокомпьютерного интерфейса. Особенностью этой проблемы является требование устойчивости у моделей. При построении систем нейрокомпьютерного интерфейса используются линейные модели. Важным аспектом создания таких моделей является построение надежного признакового пространства. В данной статье рассматривается построение признакового пространства на данных электрокортикограммы для метода частичной регрессии наименьших квадратов

Основной вклад данной работы заключается в учете пространственной зависимости в модели. В нашем подходе используется пространственная аппроксимация искомого сигнала с помощью нормального распределения и полиномов. Информация об аппроксимации учитывается при создании признакового пространства. В статье приведены результаты численных экспериментов на данных электрокортикограмм головного мозга обезьян.

Ключевые слова: *отбор признаков; нейрокомпьютерный интерфейс; электрокортикограмма; локальные модели*

1 Введение

Нейрокомпьютерный интерфейс (BCI) [1] считывает сигналы нейронов головного мозга, анализировать их и переводить в команды исполняющей системы. Исследования в данной области позволяют людям с нарушениями двигательных функций организма заменить или восстановить их. Примером такой системы является система управления роботизированным протезом посредством мозговых импульсов.

Мозговая активность представляет собой совокупность электрических импульсов различной амплитуды и частоты, возникающих на поверхности головного мозга. Исследование мозговой активности производится при помощи электрокортикографии [2] или [3] электроэнцефалографии. В результате измерения мы получаем временной ряд напряжений сигнала, который используется как данные для задачи. В задаче используется данные из [4].

Подходы [5, 6] к решению задачи состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала. В [7–9] исследуются частотные характеристики. Основными методами решения являются PLS [8, 10, 11], PCA [10, 11]. В [12] используются алгоритмы, построенные на скрытых марковских моделях. В [9, 13] рассматриваются различные участки сигнала в виде слов. В работе [14] задача отбора признаков сводится к задаче квадратичного программирования (Quadratic Programming Feature Selection [15]). Также для решения задачи используются нейросетевые модели [16].

2 Постановка задачи

Данные электрокортикограммы представляют собой временной ряд амплитуд сигналов $\mathbf{X}(t) \in \mathbb{R}^m$, по которым нужно предсказать положение запястья в следующем момент времени $\mathbf{y}(t+1) \in \mathbb{R}^3$. В качестве выборки рассматривается $\mathcal{D} = \{(\mathbf{X}_{(i)}^n, \mathbf{y}_{i+1})\}$, где $\mathbf{X}_{(i)}^n$ — значения временного ряда с момента времени i по момент $i+n$, где n — гиперпараметер задачи и выбирается из дополнительных условий. В силу коррелированности исходных данных предлагается разбить предсказательную модель на локальную модель и модель регрессии.

Определение 1. *Локальная модель — совокупность двух параметрических отображений: φ и ψ , где φ отображает из пространства большей размерности в пространство меньшей размерности, а ψ отображает из этого же пространства меньшей размерности в исходное пространство большей размерности.*

В нашем случае под количеством информации понимается дисперсия. Оптимизационная задача на нахождение локальной модели ставится следующим образом

$$\begin{aligned}\varphi &: \mathbb{R}^{n \times k_1} \rightarrow \mathbb{R}^{n \times k_2} \\ \psi &: \mathbb{R}^{n \times k_2} \rightarrow \mathbb{R}^{n \times k_1} \\ \psi^*, \varphi^* &= \arg \min_{\psi, \varphi} \|\mathbf{X} - \psi \circ \varphi(\mathbf{X})\|_2\end{aligned}$$

Локальная модели получаем новую выборку $\mathcal{D}_{new} = \{(\mathbf{Z}_{(i)}^n, \mathbf{y}_i)\}$, $\mathbf{Z}_{(i)}^n = \varphi(\mathbf{X}_{(i)}^n)$. Эту задачу мы решаем при помощи регрессии:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{z}, \mathbf{w}, \mathbf{y})$$

Критерием качества линейной модели выступают коэффициент детерминации и корреляция Пирсона.

3 Вычислительный эксперимент

Основная цель — сравнение моделей результатов моделей с и без использования локальных моделей

3.1 План работы

- Подготовить данные
- Применить локальную модель к данным
- Подать выход локальной модели на вход PLS
- Получить результаты
- Получить результаты без использования локальной модели
- Сравнить результаты

3.2 Данные

В качестве данных для проведения вычислительного эксперимента использовались данные [4], представляющие запись электрокортикограммы головного мозга обезьяны. Каждой записи соответствует амплитуды напряжения на 32 электродах и 3 пространственные координаты. При проведении эксперимента выборка была сокращена в 10 раз.

Обработка исходных данных производится в несколько этапов и подробно описано в статье [13]. Исходный сигнал записан на частоте 1 кГц, данные о движении — на частоте

120 Гц. Сигнал фильтруется полосным фильтром с диапазоном от 0.3 до 600 Гц. Затем для каждого момента времени t строится частотно-временная характеристика. Над сигналом в окне $[t - 1.1s, t]$ с шагом в $\Delta = 100$ миллисекунд осуществляется вейвлет-преобразование на 10 различных частотах ω_j в диапазоне от 10 до 150 Гц. Затем строится матрица 10×10 , элементами которой s_{ij} является квадрат амплитуды на частоте ω_j в момент времени $t - (1 + i)\Delta$. Таким образом, размер описания одного объекта (момента времени) составляет $N_{ch} \times 10 \times 10$.

При проведении эксперимента разбиение выборки производится в следующем соотношении: 80% — обучение, 20% — тестирование.

3.3 Алгоритм

3.4 Метод частичных квадратов (PLS)

Метод частичных наименьших квадратов проецирует матрицу плана \mathbf{X} и целевую матрицу \mathbf{Y} в скрытое пространство малой размерностью l ($l < M$). Метод PLS находит в скрытом пространстве матрицы $\mathbf{T}, \mathbf{U} \in \mathbb{R}^{m \times l}$, которые лучше всего описывают оригинальные матрицы \mathbf{X} и \mathbf{Y} . При этом PLS максимизирует взаимосвязь между \mathbf{T} и \mathbf{U} . Матрица плана \mathbf{X} и целевая матрица \mathbf{Y} проецируются в скрытое пространство следующим образом:

$$\begin{aligned} \mathbf{X}_{m \times n} &= \mathbf{T}_{m \times l} \cdot \mathbf{P}_{l \times n}^T + \mathbf{F}_{m \times n} = \sum_{k=1}^l \mathbf{t}_k_{m \times 1} \cdot \mathbf{p}_k^T_{1 \times n} + \mathbf{F}_{m \times n}, \\ \mathbf{Y}_{m \times r} &= \mathbf{U}_{m \times l} \cdot \mathbf{Q}_{l \times r}^T + \mathbf{E}_{m \times r} = \sum_{k=1}^l \mathbf{u}_k_{m \times 1} \cdot \mathbf{q}_k^T_{1 \times r} + \mathbf{E}_{m \times r}. \end{aligned}$$

Здесь \mathbf{T} и \mathbf{U} — образы исходных матриц в скрытом пространстве, причём столбцы матрицы \mathbf{T} ортогональны; \mathbf{P} и \mathbf{Q} — матрицы перехода; \mathbf{E} и \mathbf{F} — матрицы остатков. Метод PLS максимизирует линейную зависимость между столбцами матриц \mathbf{T} и \mathbf{U}

$$\mathbf{U} \approx \mathbf{T}\mathbf{B}, \mathbf{B} = \text{diag}(\beta_k), \quad \beta_k = \mathbf{u}_k^T \mathbf{t}_k / (\mathbf{t}_k^T \mathbf{t}_k).$$

3.5 Результаты

.

.

Литература

- [1] Jerry J Shih, Dean J Krusienski, and Jonathan R Wolpaw. Brain-computer interfaces in medicine. In *Mayo Clinic Proceedings*, volume 87, pages 268–279. Elsevier, 2012.
- [2] N Jeremy Hill, Disha Gupta, Peter Brunner, Aysegul Gunduz, Matthew A Adamo, Anthony Ritaccio, and Gerwin Schalk. Recording human electrocorticographic (ecog) signals for neuroscientific research and real-time functional cortical mapping. *JoVE (Journal of Visualized Experiments)*, (64):e3993, 2012.
- [3] Michael J Aminoff. Electroencephalography: general principles and clinical applications. *Electrodiagnosis in Clinical Neurology*, 6th ed.; Aminoff, MJ, Ed, pages 37–84, 2012.
- [4] Zenas C Chao, Yasuo Nagasaka, and Naotaka Fujii. Long-term asynchronous decoding of arm motion using electrocorticographic signals in monkey. *Frontiers in neuroengineering*, 3:3, 2010.
- [5] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiro Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ecogs during periodic movements. *Frontiers in neuroscience*, 8:417, 2014.
- [6] David M Alexander, Peter Jurica, Chris Trengove, Andrey R Nikolaev, Sergei Gepshtein, Mikhail Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, et al. Traveling waves and trial averaging: the nature of single-trial and averaged brain responses in large-scale cortical signals. *Neuroimage*, 73:95–112, 2013.
- [7] César Márquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral components and kinematic recordings. *Journal of neural engineering*, 4(2):146, 2007.
- [8] Andrey Elishev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand trajectories from ecog signals using the generalized additive model. *Journal of neural engineering*, 11(6):066005, 2014.
- [9] Carlos A Loza and Jose C Principe. Unsupervised robust detection of behavioral correlates in ecog. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*, pages 509–512. IEEE, 2017.
- [10] Andrey Elishev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ecog) recording. *PloS one*, 11(5), 2016.
- [11] Roman Rosipal and Nicole Kramer. Overview and recent advances in partial least squares. In *International Statistical and Optimization Perspectives Workshop Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer, 2005.
- [12] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*, pages 1858–1862. IEEE, 2014.
- [13] Hai-bin Zhao, Chun-yang Yu, Chong Liu, and Hong Wang. Ecog-based brain-computer interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International Conference on Biomedical Engineering and Informatics*, volume 2, pages 873–877. IEEE, 2010.
- [14] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ecog-based brain-computer interface. *Expert Systems with Applications*, 114:402–413, 2018.
- [15] Irene Rodriguez-Lujan, Ramon Huerta, Charles Elkan, and Carlos Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 11(Apr):1491–1516, 2010.
- [16] Ziqian Xie. Deep learning approach for brain machine interface. 2018.

Поступила в редакцию